

数据结构与 DataLoader 设计

核查日期：2026-09-16。依据四张 CSV、样板/info.json、完整样板 TXT，以及提供的平台字段说明截图。统计包含测试记录；原始文件未修改。本文是设计规格，尚未实现生产训练用 Dataset/DataLoader。

1. 数据集概况

文件	数据行数	不同 healthid 数	实测编码	一行的含义
传感器原始数据.csv	1165	40	UTF-8（按 utf-8-sig 可读取）	一条传感器附件记录，包含用户、时间范围和 ZIP 对象路径
用餐信息1.csv	288	41	GB18030 可正确解码	一次用餐记录及问卷、图片附件索引
用餐信息2.csv	169	31	GB18030 可正确解码	同一类用餐记录的部分导出
用户信息.csv	60	43	GB18030 可正确解码	一条用户资料记录；同一用户可能有多条

以上 healthid 数是平台用户标识数量，不能未经身份核对直接等同于独立受试者人数。

1165 条传感器记录的 uniqueid 和附件路径均唯一。它们是文件索引，不是 1165 个训练样本，也不代表 1165 顿饭。一个 ZIP 可以跨较长时间、有多段有效采样，并对应零次或多次用餐；一顿饭也可能跨 ZIP。

用餐表 2 的 169 个 uniqueid 全部包含于用餐表 1。除最后一条截断记录外，重叠记录在将时间统一到秒后内容一致。最后一条的 foodName 在换行处截断，后续四个字段缺失；表 1 中该记录完整。建议当前直接以用餐表 1 为用餐数据源，表 2 仅用于核对，不拼接出 457 条用餐。

2. 公共字段

字段	平台定义	训练数据处理
uniqueid	数据唯一 ID	在各自表内标识记录。传感器记录 ID、用餐记录 ID、资料记录 ID 含义不同，不能直接跨表等值连接
healthid	用户 ID、用户唯一标识	跨表关联的主要平台键。另建经核对的 subject_id 表示真实受试者
externalid	用户自定义的外部 ID	通常形如 HNU21017，用于受试者映射和人工核查；实际存在拼写、大小写、空值与复用，不能直接当可靠主键
uploadtime	上传时间	数据上传/入库信息，用于溯源与版本核查，不作为信号时间或用餐标签时间
recordtime	数据产生时间	该条记录的时间；不能代替其内部采样范围或用餐范围

截图中 uploadtime/recordtime 定义为 Integer，但 CSV 导出已部分转换成日期文本。要兼容毫秒整数与 YYYY-MM-DD HH:MM:SS 两种表现形式。日期文本按本项目北京时间 UTC+8 解释，内部统一成 int64 Unix 毫秒；已有毫秒整数不要再次加 8 小时。日期文本已丢失的毫秒精度无法恢复。

3. 传感器原始数据表

除公共字段外：

字段	平台定义	用法与限制
groupid	记录分组 ID	保留来源分组信息，不得擅自解释成一次用餐、连续采样会话或用户 ID
timeStamp	采集数据起止时间戳，TimeFrame	内含 startTime/endTime，当前数值为毫秒。用于文件范围初筛；真正可用区间须检查 TXT 内各模态时间戳
deviceType	设备类型	1164 条为 HUAWEI WATCH JNA，1 条空。用于设备域分析与质量检查
sensorData	传感器原始文件，Attachment	kitattachments/.../sensorData-....zip 是服务器对象路径。下载后映射至本地 ZIP；模型输入来自 ZIP 内的采样值
sensorType	传感器原始数据类型，Array	全部记录为["acc","ppg"]，但样板还包含 GYRO 字段，应结合真实文件检查可用模态
recordschema	元数据版本	当前全为 1。保留在缓存配置和解析版本检查中

timeStamp 是 Python 字典风格文本，如 {'startTime': ..., 'endTime': ...}，使用受控 JSON/Python literal 解析，不能简单按逗号拆分，也不能使用 eval。

传感器表范围为北京时间 2026-07-09 18:53:12 至 2026-08-02 19:47:51。文件声明时长中位数 4421 秒，最短 205 秒，最长 945805 秒（约 10.95 天）。最长记录属于 HNU21004，应复核其真实采样范围。

同一 healthid 下有 61 条记录与此前某条记录的声明时间范围重叠。逐条相加约 3317.27 小时，按用户合并时间区间约 3258.19 小时。这两个数都不是有效信号时长，不能直接用于训练规模或佩戴时长结论。

4. 用餐信息表

除公共字段外，两张表具有相同业务字段：

字段	平台定义	训练用途
dietaryType	饮食类型	早餐、午餐、晚餐、上午/下午/晚上加餐。是用餐事件属性；并非逐口动作标签
timeFrame	用餐时间，TimeFrame	startTime/endTime 为用餐区间。与信号对齐的主要标签来源
beforeTime	餐前图片时间	图片拍摄/记录时间，不能作为用餐开始时间的替代值
afterTime	餐后图片时间	图片拍摄/记录时间，不能作为用餐结束时间的替代值

字段	平台定义	训练用途
drinkingVolume	饮水量	包含 300mL 等点值、500–1000mL 范围、1000mL以上和缺失。保留原文，并拆成 lower_ml、upper_ml、类别/缺失标记；不要把区间硬转成一个精确数
satiety	饱腹情况	刚刚好、有点撑、没吃饱。可作单独的事件级预测目标，不作为进食识别的默认输入
foodName	食物名称和份量	自由文本，可含换行。可能用于食物/营养相关后续任务；不能仅凭文本自动得到准确热量或营养标签
tablewareType	餐具类型	筷子、刀叉、勺子、手、无需餐具。适合按餐具分层评估或多任务标注
dietaryHand	饮食惯用手	左手/右手。用餐动作和手表所在手是否一致会影响信号
wearHand	设备佩带手	本次用餐填写的左手佩戴/右手佩戴，属于事件级上下文
diningPictures	用餐图片，Attachment	图片 ZIP 对象路径。当前传感器样板不是该图片附件的样板，内部图片格式和前后餐对应规则尚未核查

表 1 中：晚餐 129、午餐 117、早餐 27、晚上加餐 10、下午加餐 4、上午加餐 1。用餐时长中位数 928 秒（15 分 28 秒）；6 条小于 60 秒，最短 2.16 秒。它们可能是误操作、时间填报问题或特殊记录，应保留质量标记，不能未经检查全部当作可靠短餐。

标签粒度只到“某段时间在用餐”。这些记录不能直接提供每次抬手、每一口、咀嚼或吞咽动作的真值。

5. 用户信息表

除公共字段外：

字段	平台定义	实测与用途
height	身高	151–183；量级推测单位 cm，截图未给单位，需采集协议确认
weight	体重	40–103；量级推测单位 kg，需确认
age	年龄	22–28；通常按岁解释，保留采集时值
gender	性别	男/女；用于群体分层和可选人口学特征
wear	佩戴手	左手佩戴/右手佩戴。是资料记录中的佩戴信息，与具体用餐 wearHand 区别保存
wrist	腕围	140–159；量级推测单位 mm，需确认
airbag	气囊型号 S/M/L	当前 60 条全部为 M，无类别变化，模型无需作为有效区分特征

60 行对应 43 个 healthid，其中 11 个 healthid 有多条资料。按 healthid 分组，身高、体重、年龄、佩戴手分别有 5、7、3、2 个分组出现不同值。不要把用户表直接 merge 进每条采样，造成行数成倍增加。

先核对受试者映射，再选择与采集时间匹配的资料版本，记录匹配方式。需要严格模拟当时可用信息时，采用采集时间之前最近的资料；没有历史记录则标缺失，不静默使用未来资料。资料中的佩戴手和用餐填写的佩戴手冲突时，分别保留并标记来源。

6. ZIP 结构

```
1 | sensorData-....zip
2 |   └─ info.json
3 |   └─ collect_data0_1784621258_1784634352.txt
```

info.json 包含 files 文件清单、filename、contentype、metadataname、metadataversion、timestamp，以及 projectcode、uploadid。样板的 metadataname 为 SensorOriginalData、版本 1。其 timestamp 为 2026-07-21 20:15:00.912+08:00，是文件元信息时间，不能替代采样时间；采样本身最晚在 19:45 左右结束。

通过文件名时间范围和 uploadid，可对应传感器表中 HNU21017 的记录：

- uniqueid：F0:FA:C7:49:6A:8B_1784621258_1
- ZIP：sensorData-1784636100913-0febac83964a4034bb6774a4c433c97a.zip
- CSV 声明范围：2026-07-21 16:07:38 至 19:45:52。

TXT 使用制表符分隔，包含 499221 行数据、53 列，无空单元格，本样板全部为整数：

字段	数量	含义
ACC_TIME	1	加速度数据对应的时间戳
PPG_TIME	1	PPG 数据对应的时间戳
GYRO_TIME	1	陀螺仪数据对应的时间戳
ACC_X / ACC_Y / ACC_Z	3	三轴加速度原始值
GYRO_X / GYRO_Y / GYRO_Z	3	三轴角速度原始值
PPG1-PPG44	44	导出的 PPG 字段，具体光源/探测器/辅助通道映射尚需设备协议确认

ACC 和 GYRO 合起来可作为六轴 IMU 输入。坐标轴物理方向、量程、缩放系数、PPG 各字段的物理语义没有出现在这些文件中，不应自行转换成 m/s²、rad/s 或指定某列是绿光/红外。

有效数据、重复时间戳和中断

模态	时间戳 > 0 的行数	时间戳为 0 的行数	同时间戳批次的常见样本数	相邻批次的常见时间差
ACC	463159	36062	10	94 ms
GYRO	462790	36431	10	94 ms
PPG	108225	390996	15	602 ms

本样板中，某模态时间戳为 0 时，对应的全部信号字段也为 0。这表明这些行没有该模态有效样本。应按模态单独过滤并保留缺失信息，不能将它们作为真实零信号参与标准化。

重复时间戳下的信号值会变化，应保留全部样本及其批内顺序，不能按 timestamp 去重。相同文本行也不能被默认解释为三个模态严格同步，尤其在启动和缺失阶段。

按稳定批次的“批内样本数 / 批次时间差”估计，ACC/GYRO 约 106 Hz，PPG 约 25 Hz。这是文件观测估计，不是已经确认的设备标称采样率。需要确认批次时间戳表示首样本、末样本还是回调时刻，才能恢复逐样本时间。不能直接按 100 Hz 和 25 Hz 从文件起点连续编号。

PPG1–20 在本样板中有非零值，PPG21–44 全部为 0。仅能得出该样板的结论。全量扫描并确认协议前，不应永久删除后 24 个字段。


ACC 实际首尾为 16:07:32.256 至 19:45:51.836，跨度 13099.58 秒；以相邻批次间隔 > 1 秒作此次诊断的分段阈值，得到 9 段，段内首尾跨度合计约 4348.65 秒（72.48 分钟）。最大片段间隔约 92.66 分钟。这是用于揭示中断的近似统计，未补偿批内时间，不是精确佩戴时长。1 秒是诊断阈值，正式分段阈值应按模态批次周期配置。

对应的晚餐区间为 18:35:57 至 19:03:50。虽然完全落在 CSV 声明的文件范围内，样板中 18:37 至 18:39 附近仍存在采样缺口。因此“附件时间范围覆盖用餐”不等于“信号完整覆盖用餐”。

7. 三类数据怎样关联

训练数据以传感器数据为主表（按用户确认的规则）。只从可用的传感器记录及其有效采样段生成训练窗口，用户资料和用餐记录作为附加信息，不单独生成训练样本。

- 用户资料：只关联传感器主表中存在的 healthid，并按资料版本规则选择记录；没有对应传感器数据的资料直接忽略，不进入训练索引。
- 用餐信息：按相同 healthid 和时间区间交叠关联。没有对应传感器数据的用餐直接忽略；只有部分交叠时，仅对实际有信号的部分生成标签。CSV 声明范围用于初筛，最终以附件内有效采样区间为准。
- 传感器记录：不因没有用餐交叠而删除，保留为窗口候选；无用餐标注的窗口按标签可信度规则处理，不自动视为非用餐。缺少资料时保留缺失标记，不通过内连接丢弃信号。
- “忽略”仅指不参与训练索引和标签构建，不删除或修改原始 CSV。辅助表的孤立记录不阻塞 DataLoader 构建，也不需要先补齐这些记录。



40 个传感器 healthid 在用餐表和用户表中都能找到；用餐表有 1 个 healthid 没有传感器记录。只按 healthid 和 CSV 声明范围计算，288 顿饭中 269 顿完全覆盖、5 顿部分覆盖、14 顿没有覆盖。这里还没有用全部 ZIP 的有效采样区间复核。

身份字段存在需先核对的情况：跨四张表有 13 个 healthid 对应多个 externalid；HNU21007、HNU21040 各自对应两个 healthid。也有 HNU21028/HNU21029、HNU21018/HNU21043 这样不能仅按拼写差异解释的组合。应区分输入错误、账户变更和账户复用。

建立显式 subject_mapping，保存 healthid、externalid_raw、subject_id、适用时间范围、核对状态。大小写和首尾空格可规范化，但不要自动把不同编号合并为同一受试者。

训练/验证/测试必须按核对后的 subject_id 分组。在映射尚未核对时，可暂时将共享 healthid 或相同有效外部编号的关联记录放入同一防泄漏组，或隔离身份不明记录。不要随机按 ZIP 或滑动窗口划分；同一个人的相邻窗口不能落入不同集合。防泄漏分组不等于确认这些记录属于同一个人。

8. DataLoader 分层设计

采用 ZIP 按需读取策略，长期只保存原始 ZIP 和轻量索引，不全量解压或永久缓存全部信号。第一版保留 ACC、GYRO、PPG 三路独立时间轴。具体框架尚未确定，下面的数据契约与框架无关。

A. 元数据与附件清单

构建标准化 recordings、meals、profiles、subject_mapping 四类索引，不改源 CSV。

构建顺序为 recordings → 有对应信号的辅助记录 → 窗口索引。以传感器主表为驱动关联辅助表，禁止用用户表或用餐表的行数决定训练样本数；一对多关联在索引层保存，不能将原始信号行展开复制。

- recordings: recording_id、healthid、subject_id、externalid_raw、声明起止时间、ZIP 对象路径、本地路径、可用状态、来源表行号。
- meals: meal_id、healthid、subject_id、用餐起止时间、餐别、事件属性、标签质量标记。
- profiles: 资料 ID、用户与受试者 ID、资料时间、各字段原值/规范值、资料版本匹配状态。
- 附件状态至少区分 missing、invalid_zip、schema_error、ready；按 sensorData 的实际映射匹配文件，不依赖目录遍历顺序，也不将缺失附件当负样本。
- 支持继续下载时增量准备，只处理已完整落盘且通过检查的 ZIP。最终清单报告预期数、成功数、缺失数和失败原因。

B. 按需解压、读取与清理

按用户最新要求，不进行全量批量解压。1165 个 ZIP 实测共 17,976,369,365 字节（约 17.98 GB），声明解压大小合计 100,008,791,444 字节（约 100.01 GB）。采用“保留 ZIP → 按需临时解压单个文件 → 读取该文件的窗口 → 删除临时副本”的生命周期，无需重新压缩。原 ZIP 始终只读。

每个 ZIP 读取 info.json 的文件清单，逐个处理 TXT，不假设未来所有 ZIP 永远只有一个 TXT。读取时用标准 CSV/TSV 解析器，支持引用字段与换行。只解压所需成员，校验成员路径不能逃逸临时目录，并在完整读取时验证 CRC。

临时目录的叶目录沿用 ZIP 文件名（去掉 .zip），上层按训练运行和 worker 隔离：

```
1  原附件目录/
2      sensorData-....zip          # 永久保留
3  loader_tmp/<run_id>/worker_<id>/
4      sensorData-.../            # 仅在使用该 ZIP 时存在
5          info.json
6          collect_data....txt
```

默认每个 worker 同时只持有一个已解压 ZIP，第一版从 num_workers=0 开始。先按 ZIP 打乱文件顺序，再在文件内通过窗口索引或有限窗口缓冲打乱顺序；不要全局随机抽一个窗口就重新解压一次文件。按文件分配 worker，避免同一 ZIP 在多个 worker 重复解压；分布式运行还须按 rank 分片。

文件读取与清理放在受控上下文中：正常消费结束或异常时关闭 TXT、数组映射等句柄，再在 finally 中删除该任务拥有的临时目录。Windows 下先释放映射，再删除文件。批次返回独立内存中的数据，不返回仍引用待删除文件的视图。提前结束 epoch 时显式关闭迭代器/worker；不能仅依赖析构函数。进程被强制终止可能留下临时目录，下次启动只清理已确认不再使用、且归本加载器所有的残留目录。

设置 max_temp_bytes（例如初始 2 GiB，可配置），将正在解压的文件、已就绪文件及可选临时数组全部计入预算。多 worker 必须共享预算并在解压前预留空间，不能各自认为有完整预算。单文件超预算时切换为 ZIP 成员流式读取和分块解析，或明确报告无法处理；不突破上限。并行 worker 越多，磁盘与内存需求越大，预取窗口也须有界。

Python ZIP 成员支持顺序解压读取。流式模式可以不落盘 TXT，按块解析并跨块保留窗口边界所需的尾部数据。该模式适合进一步降低磁盘占用，但压缩文本不支持廉价随机寻址，不能对每个随机窗口重新从头解压。

若随机访问确有需求，可将当前文件转换成临时 .npy 模态数组，用内存映射读取；TXT 和数组的峰值共存空间须计入预算，文件用完后一起清理。不得据此恢复为全数据集永久信号缓存。原始整数尤其 PPG 应保留精度，做居中/缩放时使用足够精度，生成模型输入再转 float32；时间戳使用 int64。

首次索引构建可逐个 ZIP 扫描，只长期保存用户/时间、连续段、批次与窗口位置、质量标记等轻量索引，不保存全量信号。索引版本包含源文件指纹、解析配置、通道配置和时间恢复规则。每个 epoch 重新访问 ZIP 仍会产生解压和解析开销；这是节省磁盘的明确取舍。训练结束后的磁盘状态为原始 ZIP 加轻量索引。

C. 时间恢复、分段与窗口索引

1. 分别提取各模态 time > 0 的数据，保留原行号和批内序号。
2. 按各自时间轴检测回退、批次周期变化和中断，形成连续段。跨文件只有同一受试者、设备和时间确实连续且重叠处理明确时才允许拼接。
3. 在采集协议确认后，按首/末样本时间语义和批内采样率恢复逐样本时间，同时保留观测的原始时间戳。协议未确认时，输出批次时间和不确定性，不能宣称已精确对齐。
4. 用真实时间窗口分别截取 ACC/GYRO/PPG。先在连续段内处理，禁止跨数分钟或数小时缺口插值。短缺口的允许长度、插值方法与 mask 规则必须明确配置。
5. 若模型要求六轴等长 IMU，在同一时间网格上对齐 ACC/GYRO 后再拼接。PPG 可保持自己的采样率，经独立分支编码后融合。降采样时使用抗混叠处理。
6. 生成 window 索引，记录受试者、源文件、段号、起止时间、各模态切片范围、质量、标签、所属 split。不要把全部重叠窗口的信号复制保存多份。

输入窗口长度与步长应是配置项。用餐区间识别可先试 30 秒窗口、15 秒步长作为工程起点，具体选择取决于训练目标与模型感受野；逐口动作识别需要另外的动作标注和时间精度。

D. 标签策略

将时间区间统一为左闭右开 $[start, end)$ 。计算窗口与该受试者用餐区间并集的重叠比例 `meal_fraction`，不对重叠餐次重复累计。

对于用餐/非用餐窗口任务，可约定：窗口完全位于可信用餐区间内为正样本；边界窗口保存软比例或标记忽略。只有确认用餐记录完整、该段有效佩戴信号时，用餐之外的区间才能作为可信负样本。未标注不能自动等同于非用餐。

建议最小标签表示为 `label=1/0/-1` 与 `label_mask`：1 为可信用餐，0 为可信非用餐，-1 为未知/忽略。未知窗口可用于自监督预训练，但不参加普通监督分类损失。低质量用餐、测试记录和身份不明记录先隔离。

如果目标是直接预测早餐/午餐/晚餐，需要仅在可信用餐事件上定义任务，并检查时间信息是否让模型仅凭时钟分类。若目标是逐口检测，目前的用餐表只能给弱监督标签。

E. Dataset 与批处理返回契约

训练读取按 ZIP 生命周期组织：按需解压或流式解析一个文件，连续生成其多个窗口，执行配置明确的变换与打包，再释放临时数据。通常每个 epoch 每个被访问的 ZIP 处理一次，避免每个窗口重复解压。训练过程不联网。

对齐和采样策略确定后的一个样本建议返回：

```
1 sample = {
2     "signals": {
3         "imu": ...,          # float32 [6, T_imu], 配置可仅取 acc
4         "ppg": ...,          # float32 [C_ppg, T_ppg]
5     },
6     "valid_mask": {
7         "imu": ...,          # bool [6, T_imu]
8         "ppg": ...,          # bool [C_ppg, T_ppg]
9     },
10    "relative_time_s": {
11        "imu": ...,           # [T_imu], 相对窗口起点，避免大 epoch 数值
12        "ppg": ...,           # [T_ppg]
13    },
14    "target": {
15        "label": ...,          # int64, 未知为 -1
16        "label_mask": ...,     # bool, 监督损失是否使用
17        "meal_fraction": ...,  # float32, 0..1; 标签未知时不能当真值
18    },
19    "meta": {
20        "subject_id": ...,
21        "recording_id": ...,
22        "window_start_ms": ..., # int64
23        "window_end_ms": ...,
24        "meal_ids": ...,
25        "quality_flags": ...,
26    },
27 }
```

若使用 PyTorch, Dataset 实现 `__len__` 和 `__getitem__`; 批处理函数将定长信号堆叠为 [B, C, T], 变长信号先 padding 并同步生成 mask, meta 保留为列表。训练器只消费 signals、valid_mask 和 target; 身份、餐类、饱腹感、用餐时间及 meal_fraction 等标签相关信息不默认作为信号识别模型的输入。

按文件顺序生产窗口时优先使用 IterableDataset, 显式按 worker/rank 分配 ZIP, 并在文件内做有界打乱; 若使用具有 `getitem` 的 Dataset, 则必须搭配按文件组织的批次采样器, 避免通用 shuffle 导致反复解压。窗口数以已构建索引为准。

Windows 下多进程读取入口应放在 `if __name__ == '__main__':` 内, Dataset/批处理函数放模块顶层。先用单进程读取验证正确性, 再调整 worker 数; 各 worker 按需打开自己拥有的临时文件, 不把全量信号常驻 Dataset 后再复制给每个 worker。

F. 标准化和评估

- 按已确认受试者划分集合后, 仅用训练集合、有效样本拟合各通道的标准化参数, 再应用到验证/测试。
- 保留缺失 mask。不要用全零占位行估计均值、方差, 也不要将原始大幅度 PPG 与 IMU 直接混在同一尺度。
- 通道选择写入全局配置, 不能每个文件按本文件的非零列动态变更维数。固定 44 个 PPG 字段加通道 mask 是保守方案; 确认完整协议后也可选择固定有效子集。
- 不随机拆分同一受试者的窗口。记录按餐次和受试者的指标; 高度重叠窗口不能被当作相互独立的新实验对象。
- IMU-only 和 IMU+PPG 可使用同一索引与输出协议进行比较。是否要求所有模态都有效由任务配置明确决定。

9. 实现前仍需确认的事项

1. 训练目标: 用餐区间识别、餐别分类、逐口动作检测或其他目标; 目前数据能直接提供的是用餐区间和事件属性。
2. 采集协议: ACC/GYRO 原始值缩放、坐标系、批时间戳语义、真实采样率、PPG1-44 的字段映射。
3. 受试者编号映射, 以及用餐是否完整记录。它们分别决定防泄漏划分和负样本可信度。
4. 训练框架和模型希望收到的输入形式。上述缓存和标签层可以先保持通用。

10. 本次核查边界

四张 CSV 已逐条解析并比较; 样板 TXT 已全量读取。其余 ZIP 尚未逐一进行信号结构与质量审计, 因此样板采样率、通道可用性与中断比例不能推广到全数据集。没有修改下载脚本、CSV、ZIP 或样板。分析脚本 `analyze_training_data.py` 可复现主要表统计与样板检查, 依赖现有 NumPy/Pandas 环境。